Melhor IA por função, com o mínimo de tokens

Plataforma Multi-IA · preparado pelo Claude para Luis e sócio · 12 de outubro de 2026

Para quê: escolher o modelo de cada papel do time de IAs. **Critério:** o melhor desempenho por dólar, não o melhor absoluto. Modelos avaliados: os das três APIs que o projeto usa (Anthropic, OpenAI e Google), mais uma alternativa barata como referência.

1. Recomendação por função

Função	Recomendado (esforço)	Reserva	Por quê	Custo/ tarefa*
Chefe (planeja e divide o trabalho)	**GPT-6.1 Sol** (médio)	Claude Sonnet 5.5 (médio)	Melhor inteligência por dólar: índice 48 a US$ 0,21 por tarefa. O Sonnet 5.5 no mesmo nível (47, esforço alto) custa US$ 0,88, cerca de 4x, porque gasta mais tokens [7]. Planejar é texto curto e não exige o topo.	US$ 0,21
Front-end (telas, HTML/CSS, visual)	**GPT-6.1 Sol** (máximo)	Claude Sonnet 5.5 (alto)	4º no ranking WebDev (1755), à frente do Sonnet 5.5 no esforço alto (6º, 1715), e mais barato por tarefa (US$ 0,72 contra 0,88) [7][8]. Se o visual for o produto, o Sonnet 5.5 no esforço xhigh é o 3º (1774), a US$ 2,01.	US$ 0,72
Back-end (APIs, banco de dados, lógica, terminal)	**Claude Sonnet 5.5** (alto)	GPT-6.1 Sol (alto)	Lidera o Terminal-Bench 4.0 (63,6% na medição independente; 70,6% segundo a Anthropic) e o ranking de código da BenchLM (SWE-bench Pro de 81,3%) [9][10][11]. Fica à frente até do Opus 5.5 nesse teste, custando metade.	US$ 0,88
Revisor de código (aponta erros)	Sempre de **família diferente** de quem escreveu: código do GPT revisado pelo **Claude Sonnet 5.5** (médio); código do Claude revisado pelo **GPT-6.1 Sol** (alto)	Claude Haiku 5.5 (alto), para uma primeira passada barata	Um revisor de outra família pega erros que o autor tende a repetir. Revisar é ler muito e escrever pouco, então o custo está na entrada, e o cache derruba esse custo [2][12].	US$ 0,32 a 0,48
Consolidação (aplica as correções e entrega)	O **mesmo modelo que escreveu** o código, no mesmo esforço	A reserva de quem escreveu	Mantém o estilo do código e reaproveita o cache do que já foi enviado (leitura em cache custa cerca de 5% da entrada normal) [2][12].	igual ao autor
Tarefas simples (resumir, classificar o pedido, títulos, extrair dados)	**Claude Haiku 5.5** (alto)	GPT-6 Luna (alto)	Índice 38 a US$ 0,08 por tarefa; a Luna faz 33 a US$ 0,03 [7]. Os dois custam US$ 0,10/0,50 por milhão de tokens. No Haiku, pedidos acima de 100 mil tokens custam 5x mais [2].	US$ 0,03 a 0,08
Casos difíceis (projeto grande, arquitetura)	**Claude Opus 5.5** (alto)	GPT-6 Astra (médio)	1º no índice geral (58 no máximo) e 1º no WebDev. No esforço alto: índice 54 a US$ 1,82 por tarefa [7][8]. Usar só quando o Sonnet ou o Sol travarem.	US$ 1,82

** Custo médio por tarefa no conjunto padrão de testes da Artificial Analysis [7]. Serve para comparar modelos entre si, não para prever quanto custa uma execução da nossa receita: esse número sai da medição da T9.*

2. Modelos comparados

Modelo	Preço (US$/milhão: entrada / saída)	Índice AA (esforço)	Custo/ tarefa (US$)	WebDev (posição)	Situação
Claude Opus 5.5	4 / 20	54 (alto) · 58 (máx)	1,82 · 5,98	1º (máx)	Disponível
Claude Sonnet 5.5	2 / 10	47 (alto) · 52 (xhigh)	0,88 · 2,01	3º (xhigh) · 6º (alto)	Disponível
Claude Haiku 5.5	0,10 / 0,50 (até 100 mil tokens)	38 (alto) · 43 (máx)	0,08 · 0,21	30º (alto)	Disponível
Claude Fable 5.1	10 / 50	53 (máx)	7,63	5º (máx)	Caro
GPT-6 Astra	10 / 50	51 (alto) · 53 (máx)	1,73 · 3,26	2º (máx)	Disponível

Modelo	Preço (US$/milhão: entrada / saída)	Índice AA (esforço)	Custo/ tarefa (US$)	WebDev (posição)	Situação
GPT-6.1 Sol	2 / 10	48 (médio) · 50 (alto) · 52 (máx)	0,21 · 0,32 · 0,72	4º (máx)	Disponível
GPT-6 Luna	0,10 / 0,50	33 (alto) · 38 (máx)	0,03 · 0,07	34º (máx)	Disponível
Gemini 4 Argon	2 / 10 (introdutório; depois 4 / 20)	53 (alto)	1,99	9º (preliminar)	Acesso restrito
Gemini 3.8 Flash	0,75 / 3,75 (até 31/12/2026; dobra em 2027)	40 (médio) · 41 (alto)	0,93 · 1,24	31º (preliminar)	Tem plano grátis
Gemini 3.1 Pro	2 / 12	30	1,30	72º	Não recomendado
DeepSeek V4.1 Flash	0,30 / 1,20	39 (máx)	0,27	23º (máx)	Fora das 3 APIs

Fontes da tabela: preços [1][2][3][5][6][10]; índice e custo por tarefa [7]; WebDev = ranking de votos em criação de sites da Arena, de 08/10/2026 [8].

3. O que isso muda no projeto

- **Gemini fica fora dos papéis principais por enquanto.** O 3.8 Flash gasta muitos tokens para o nível que entrega (US$ 1,24 por tarefa com índice 41, contra US$ 0,32 e índice 50 do GPT-6.1 Sol), e o Argon ainda não está liberado. Ele segue como reserva e para testes no plano grátis. Reavaliar o Argon quando o acesso abrir.
- **Proposta para a receita "Criar um site"** (hoje: Chefe Claude, Programador GPT, Revisor Gemini): Chefe GPT-6.1 Sol (médio), Programador GPT-6.1 Sol (máximo), Revisor Claude Sonnet 5.5 (médio) e Consolidação GPT-6.1 Sol. A decisão final sai da medição da T9, com 3 a 5 execuções reais.
- **Receitas com back-end** (apps, sistemas): Claude Sonnet 5.5 no back-end, GPT-6.1 Sol no front-end, cada um revisando o código do outro.

4. Como gastar menos tokens

- **O esforço é a maior alavanca.** No Opus 5.5, ir do esforço máximo para o alto derruba o custo por tarefa de US$ 5,98 para 1,82 (–70%), perdendo 4 pontos de índice [7]. Começar no médio ou alto e subir só se precisar.
- **Cache:** o que se repete entre etapas (instruções, pedido, respostas anteriores) lido do cache custa cerca de 5% da entrada normal no Claude 5.5 e no GPT-6.1 Sol [2][12].
- **Mandar a cada papel só o que ele precisa.** O motor já faz isso com as partes marcadas de cada etapa.
- **Limitar o tamanho da resposta de cada papel** (já é regra do projeto) e pedir respostas diretas, sem repetir o pedido.
- **Lote (Batch API):** 50% de desconto, mas só para trabalho que pode esperar. Não serve quando o usuário está assistindo ao vivo [2].

Cuidados. *Dados de 12/10/2026: os modelos e preços mudam quase todo mês (a família GPT-6 Sol, o Opus 5.5 e o Gemini 4 Argon saíram em setembro). Vários resultados de testes são informados pelas próprias empresas; demos preferência aos independentes (Artificial Analysis e Arena). O GPT-6.1 Sol aparece no ranking WebDev só no esforço máximo; nos outros esforços, a posição dele não foi medida.*

Fontes

[1] Anthropic, visão geral dos modelos. https://platform.claude.com/docs/en/models/overview
[2] Anthropic, preços da API. https://platform.claude.com/docs/en/about-claude/pricing
[3] OpenAI, modelos da API. https://developers.openai.com/api/docs/models
[4] MacRumors, lançamento do GPT-6 Sol e Luna (22/09/2026). https://www.macrumors.com/2026/09/22/openai-gpt-6-sol-luna/
[5] Google, preços da API Gemini. https://ai.google.dev/gemini-api/docs/pricing
[6] 9to5Google, anúncio do Gemini 4 Argon (30/09/2026). https://9to5google.com/2026/09/30/gemini-4-argon-announcement/
[7] Artificial Analysis, ranking de modelos (índice e custo por tarefa). https://artificialanalysis.ai/leaderboards/models
[8] Arena, ranking WebDev (08/10/2026). https://arena.ai/leaderboard/code/webdev
[9] Artificial Analysis, Terminal-Bench 4.0. https://artificialanalysis.ai/evaluations/terminalbench-4-0
[10] Morph, melhores modelos para código (10/10/2026). https://www.morphllm.com/best-ai-model-for-coding
[11] BenchLM, melhores LLMs para código (12/10/2026). https://benchlm.ai/coding
[12] BenchLM, preços da API da OpenAI, incluindo entrada em cache (out/2026). https://benchlm.ai/openai/api-pricing